

EfficientNetB0 CNN Mimarisi Kullanarak Retina Fotoğrafları ile Diyabetik Retinopati Teşhisini Koyma Projesi Final Raporu

*

1st İsmail Dumlu

Atatürk Üniversitesi

Mühendislik Fakültesi

Yapay Zeka ve Veri Mühendisliği

Erzurum, Türkiye

ismail.dumlu24@ogr.atauni.edu.tr

2nd M. Mirza Erdem

Atatürk Üniversitesi

Mühendislik Fakültesi

Yapay Zeka ve Veri Mühendisliği

Erzurum, Türkiye

mehmetmirza.erdem24@ogr.atauni.edu.tr

3rd M. Selçuk İnci

Atatürk Üniversitesi

Mühendislik Fakültesi

Yapay Zeka ve Veri Mühendisliği

Erzurum, Türkiye

muhammedselcuk.inci24@ogr.atauni.edu.tr

240711003

240711012

240711020

Abstract—Bu projede, EfficientNetB0 mimarisi kullanılarak geliştirilen derin öğrenme modeliyle; retina fotoğraflarından hızlı ve objektif bir otomatik ön teşhis sistemi oluşturulması amaçlanmıştır. Temel hedefimiz, erken teşhis ile görme kaybı riskini minimize ederek tıbbi karar destek süreçlerini desteklemektir.

I. GİRİŞ

Diyabet, dünya genelinde giderek artan bir halk sağlığı sorunudur ve uzun vadede çeşitli organlarda ciddi komplikasyonlara yol açmaktadır. Bu komplikasyonlar dan biri olan diyabetik retinopati, retina damarlarında meydana gelen mikrodamar bozuklukları nedeniyle görme kaybına neden olabilen bir hastalıktır.

Diyabetik Retinopati, dünya genelinde yetişkinlerdeki körlüğün birincil nedenidir ve teşhisini uzman hekimler için dahi zaman alıcı bir süreçtir. Artan hasta sayısına karşın uzman yetersizliği ve manuel taramadaki hata payı, bu tip hastalıklarda otomatik teşhis sistemlerini gereklili kılmaktadır.

II. VERİ SETİ VE ÖN İŞLEME

A. Veri Seti Hakkında

Üzerinde çalıştığımız veri seti, Kaggle.com'da yer alan **Diabetic Retinopathy 224x224 (2019 Data)** isimli APTOS 2019 Blindness Detection temelli veri setidir. Bu veri setinde bir adet colored_images dosyası - Retina fotoğraflarının bulunduğu dosya - ve bir adet train.csv - Fotoğrafların ID'leri ve diagnosis (teşhis) bilgilerinin bulunduğu excel tablosu - bulunmaktadır.

Veri setindeki görüntüler, uzman oftalmologlar tarafından ICDR (International Clinical Diabetic Retinopathy) ölçüğine göre 5 sınıfa ayrılmıştır:

TABLE I
DIAGNOSIS EVRELERİ

Diagnosis	Açıklama
0 - No DR	Sağlıklı Retina
1 - Mild	Hafif düzey; genellikle mikroanevrizmalar mevcut
2 - Moderate	Orta düzey; kanamalar ve eksudular başlar
3 - Severe	Şiddetli düzey; yaygın kanama ve damar tikanıklıkları
4 - Proliferative	İleri evre; yeni damar oluşumları ve yüksek körlük riski

B. Ön İşleme

Eğitim ve doğrulama verileri, görsel kimlikleri ve sınıf etiketlerini içerecek şekilde DataFrame yapısına dönüştürülmüştür. Sayısal sınıf etiketleri ilgili klasör isimleriyle eşleştirilmiş ve her bir görüntü için görelî dosya yolları oluşturulmuştur. Bu yapı, flow_from_dataframe fonksiyonunun veriyi doğru şekilde okuyabilmesi için kullanılmıştır.

Veri ön işleme aşamasında, retinal görüntüler EfficientNetB0 mimarisine uygun olacak şekilde 224×224 piksel boyutuna getirilmiştir. Eğitim sürecinde veriler 32'lik batch'ler halinde modele sunulmuştur. Çalışmada manuel bir piksel yeniden ölçektekleme uygulanmamış, görüntüler EfficientNet'in ImageNet ön-eğitimi sırasında tanımlı olan dahili giriş normalizasyonu (preprocess_input) ile işlenmiştir. Sınıf etiketleri, (class_mode="raw") kullanılarak 0–4 arası tamsayı değerler şeklinde modele verilmiştir. İleri seviye medikal ön işleme yöntemleri bu çalışma kapsamında kullanılmamıştır.

III. METODOLOJİ VE MODEL MİMARİSİ

A. Metodoloji

Bu çalışmada veri artırma ve veri üretimi süreçleri birlikte yürütülmüştür. Eğitim verisi için tanımlanan ImageDataGenerator (datagen), rastgele geometrik dönüşümler ile görüntü

çeşitliliğini artırırken, train generator yapısı bu dönüşümleri eğitim sırasında batch bazında modele dinamik olarak sunmuştur. Böylece veri seti fiziksel olarak büyütülmeden, her epoch'ta görüntülerin farklı varyasyonları on-the-fly biçimde kullanılmıştır. Doğrulama verisi için ise yalnızca temel veri üretimi yapılmış, herhangi bir veri artırma uygulanmamıştır.

Veri artırma aşamasında, yalnızca eğitim verisi üzerinde temel geometrik dönüşümler uygulanmıştır. Bu kapsamında görüntülere rastgele döndürme ($\pm 15^\circ$), yakınlaştırma (%10), yatay ve dikey kaydırma (%10) ile yatay çevirme işlemleri uygulanmıştır. Bu yöntemler, veri çeşitliliğini artırarak overfitting riskinin azaltılmasını hedeflemektedir. Doğrulama verisi üzerinde veri artırma uygulanmamıştır.

Eğitim ve doğrulama verileri, (flow_from_dataframe) yöntemi kullanılarak batch'ler halinde üretilmiştir. Eğitim verisi için (train_generator) oluşturulmuş ve veriler her epoch'ta karıştırılarak (shuffle) modele sunulmuştur. Doğrulama verisi için ise (validation_generator) kullanılmış, gerçek etiket-tahmin eşleşmesinin korunabilmesi amacıyla shuffle işlemi uygulanmamıştır. Tüm görüntüler 224×224 hedef boyutunda okunmuş ve sınıf etiketleri (class_mode="raw") kullanılarak 0–4 arası tamsayı değerler şeklinde modele verilmiştir.

B. Model Mimarisi

Eğitim modelimizde, ImageNet üzerinde ön-eğitilmiş EfficientNetB0 backbone'u kullanılarak transfer learning tabanlı bir model mimarisi oluşturulmuştur. Backbone, yalnızca özellik çıkarıcı olarak kullanılmış ve ön-eğitimli temsillerin korunması amacıyla dondurulmuştur. Backbone'dan elde edilen özellikler Global Average Pooling ile özetlenmiş, ardından Dense ve Dropout katmanlarından oluşan bir sınıflandırıcı head aracılığıyla 5 sınıfı softmax çıkış üretimiştir.

Global Average Pooling katmanı, uzamsal boyutları özetleyerek parametre sayısını azaltmak ve özellikle medikal görüntülerde aşırı uyum riskini düşürmektedir.

Softmax aktivasyonu, model çıktılarının sınıf olasılıkları olarak yorumlanabilmesini sağlayarak klinik değerlendirme açısından anlamlı bir çıktı üretmektedir.

IV. EĞİTİM AŞAMASI

Eğitim süreci, ön-eğitimli bir derin öğrenme mimarisinin problem alanına kontrollü biçimde uyarlanması hedefleyen iki aşamalı bir strateji ile yürütülmüştür. Bu süreçte sınıf dengesizliği ve zor örneklerin öğrenimi dikkate alınarak uygun kayıp fonksiyonları tercih edilmiş, eğitim kararlılığı ve genellenebilirliği artırmak amacıyla çeşitli kontrol mekanizmaları kullanılmıştır. Model, önce genel görsel temsillerini koruyacak şekilde stabilize edilmiş, ardından diyabetik retinopati problemine özgü özellikleri öğrenmesi sağlanmıştır.

A. Sınıf Ağırlıkları ve Loss

Veri setindeki sınıf dengesizliğini ele almak amacıyla, eğitim verileri üzerinden otomatik olarak class weight değerleri hesaplanmıştır. Bu yaklaşım, az temsil edilen

sınıfların eğitim sürecine daha fazla katkı sağlamasını hedeflemektedir.

Balanced class weight değerlerinin bazı sınıflar için aşırı agresif etkilere yol açabilmesi nedeniyle, eğitim kararlılığını artırmak amacıyla bu ağırlıklar yumoşatılmış ve daha dengeli bir ağırlıklandırma elde edilmiştir.

Öğrenilmesi zor örneklerin ve az temsil edilen sınıfların modele katkısını artırmak amacıyla, yumoşatılmış sınıf ağırlıkları focal loss yapısı ile birleştirilerek weighted sparse focal loss kullanılmıştır. Sparse yapı sayesinde etiketler ham (integer) formatta doğrudan kullanılmıştır.

B. İki Aşamalı Eğitim Süreci

Eğitim sürecinin ilk aşamasında, ön-eğitimli EfficientNetB0 mimarisinin backbone katmanları dondurularak yalnızca sınıflandırıcı head katmanları eğitilmiştir. Bu aşamada, rastgele başlatılan Dense katmanların stabilize edilmesi ve modelin ön-eğitimli görsel temsillerinin bozulmadan korunması amaçlanmıştır. Yaklaşık 329 bin trainable parametrenin güncellendiği bu warm-up süreci, modelin diyabetik retinopati problemine kontrollü bir şekilde adapte edilmesini sağlamıştır.

Warm-up aşamasının ardından, modelin ön-eğitimli EfficientNetB0 backbone'unun son katmanları kademeli olarak açılarak fine-tuning uygulanmıştır. Bu aşamada daha düşük bir öğrenme oranı kullanılarak, modelin genel ImageNet temsillerinin diyabetik retinopati problemine özgü özellikler doğrultusunda uyarlanması hedeflenmiştir. Ayrıca sınıf denge-sizliği ve zor örneklerin öğrenimini güçlendirmek amacıyla, yumoşatılmış sınıf ağırlıkları ile birlikte weighted sparse focal loss kullanılarak daha dengeli ve kararlı bir eğitim süreci sağlanmıştır.

C. Eğitim Stabilitesi ve Kontrol Mekanizmaları

Eğitim sürecinde modelin kararlı bir şekilde öğrenmesini sağlamak ve aşırı uyum (overfitting) riskini azaltmak amacıyla çeşitli kontrol mekanizmaları kullanılmıştır. Bu kapsamında, doğrulama performansına bağlı olarak eğitimi durdurmak erken durdurma (Early Stopping) yöntemi uygulanmış, öğrenme sürecinin daha dengeli ilerlemesi için öğrenme oranı azaltma (ReduceLROnPlateau) mekanizmasından yararlanılmıştır. Ayrıca, en iyi doğrulama performansına sahip model ağırlıkları Model Checkpoint ile kaydedilerek değerlendirme sürecinde kullanılmıştır. Bu mekanizmalar sayesinde eğitim süreci hem kararlı hem de güvenilir bir şekilde yürütülmüştür.

Early Stopping, doğrulama performansında belirli bir süre boyunca iyileşme gözlenmediğinde eğitim sürecini otomatik olarak sonlandıran bir mekanizmadır. Bu yöntem, modelin gereğinden fazla eğitilerek doğrulama verisine aşırı uyum sağlamasını (overfitting) engellemeyi ve gereksiz eğitim sürelerini önlemeyi amaçlar. 100 epoch ile eğitime başladığınızı düşünelim, 25. epochta accuracy ve loss değerleriniz değişimmeye yahut düşmeye başlıyor. Tam o esnada Early Stopping devreye girer ve eğitiminizi 26. Epochta ya da 27. Epochta sonlandırır.

ReduceLROnPlateau, doğrulama performansının belirli bir süre boyunca iyileşmemesi durumunda öğrenme oranını

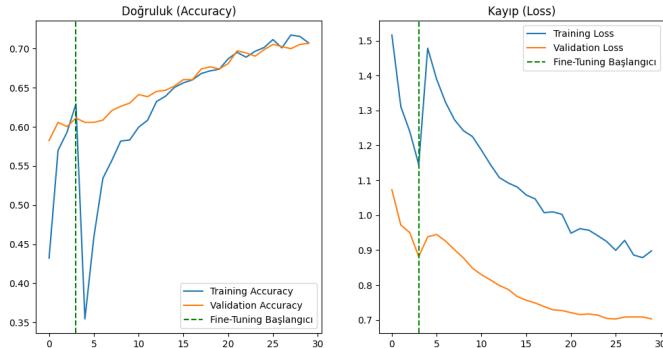


Fig. 1. Accuracy ve Loss

kademeli olarak düşüren bir kontrol mekanizmasıdır. Öğrenme oranının azaltılması, modelin minimuma daha hassas bir şekilde yaklaşmasını sağlayarak eğitim sürecinin daha kararlı ilerlemesine katkı sağlar.

Model Checkpoint, eğitim sürecinde elde edilen en iyi doğrulama performansına sahip model ağırlıklarının otomatik olarak kaydedilmesini sağlayan bir mekanizmadır. Bu sayede, eğitimin sonundaki ağırlıklar yerine en iyi performansın elde edildiği model kullanılarak daha güvenilir değerlendirme yapılır.

D. Hiperparametreler

Modelin eğitim süreci, kullanıcı tarafından belirlenen hiperparametreler ve eğitim yapılandırması doğrultusunda yürütülmektedir. Model mimarisinin ve hiperparametreler sabitlenirken, model parametreleri eğitim sırasında veriden otomatik olarak öğrenilmektedir. Öğrenme oranı, batch boyutu ve düzenleme mekanizmaları gibi ayarlar, öğrenme sürecinin kararlılığı ve genellenebilirliği üzerinde belirleyici rol oynamaktadır.

V. MODEL PERFORMANSI

Model performansı, doğrulama verisi üzerinde çeşitli değerlendirme metrikleri kullanılarak analiz edilmiştir. Sınıf dengesizliğinin etkisini daha doğru yansıtılmamak amacıyla, doğruluk (accuracy) metriğine ek olarak sınıf bazlı ölçütler ve Cohen's Kappa değeri dikkate alınmıştır. Elde edilen sonuçlar, modelin diyabetik retinopati şiddet seviyelerini ayırt etme yeteneği üzerinden değerlendirilmiştir.

A. Accuracy

Accuracy, modelin doğru sınıflandırdığı örneklerin toplam örnek sayısına oranını ifade eden temel bir performans metriğidir. Bu çalışmada accuracy metriği, modelin genel sınıflandırma başarısını özetlemek amacıyla raporlanmıştır. Ancak, diyabetik retinopati veri setinde sınıf dengesizliği bulunması nedeniyle accuracy tek başına yeterli bir değerlendirme ölçütü olarak ele alınmamış, diğer sınıf bazlı metrikler ile birlikte yorumlanmıştır.

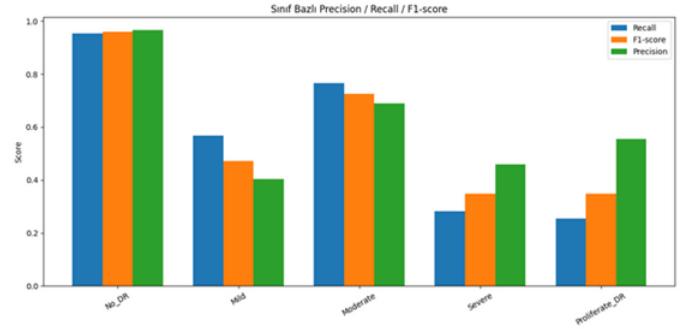


Fig. 2. Precision / Recall / F1-score

B. Precision, recall, F1-score

Precision, pozitif tahminlerin doğruluğunu; recall ise gerçek pozitif örneklerin ne kadarının doğru yakalandığını gösterir. Medikal sınıflandırma problemlerinde özellikle recall metriği kritik öneme sahiptir. F1-score, precision ve recall değerlerini dengeleyerek sınıf dengesizliği bulunan veri setlerinde daha anlamlı bir değerlendirme sunar.

C. Confusion Matrix

Confusion matrix, modelin her bir sınıf için doğru ve hatalı tahminlerini ayrıntılı biçimde göstermektedir. Bu analiz sayesinde hangi sınıfların doğru sınıflandırıldığı ve hangi sınıflar arasında karışıklık yaşandığı açıkça gözlemlenebilmektedir. Özellikle diyabetik retinopati gibi evreler arası geçişin kademeli olduğu problemlerde, hataların çoğunlukla komşu şiddet seviyeleri arasında gerçekleşmesi beklenen bir durumdur.

Elde edilen karışıklık matrisi incelendiğinde, modelin en yüksek doğruluğu No_DR sınıfında gösterdiği, Mild–Moderate ve Severe–Proliferate_DR sınıfları arasında ise görece daha fazla karışıklık yaşandığı görülmektedir. Bu durum, sınıf dağılımındaki dengesizlik ve diyabetik retinopati evrelerinin görsel olarak birbirine yakın özellikler taşıması ile ilişkilendirilebilir.

D. Cohen's Kappa

Cohen's Kappa, sınıflandırma performansını rastgele tahmin olasılığını da dikkate alarak değerlendiren bir ölçütür. Özellikle sınıf dağılımının dengesiz olduğu veri setlerinde, yalnızca accuracy metriğine kıyasla daha güvenilir bir performans değerlendirmesi sunmaktadır. Bu çalışmada Cohen's Kappa değeri, modelin diyabetik retinopati şiddet seviyelerini ne ölçüde tutarlı biçimde ayırt edebildiğini göstermek amacıyla kullanılmıştır.

$$k = (po - pe) / (1 - pe) \quad (1)$$

po (Observed agreement): Gerçek doğruluk

pe (Expected agreement): Şans başarısı

Elde edilen Cohen's Kappa değeri, modelin yüksek doğruluk değerlerine rağmen rastgele sınıflandırmadan anlamlı biçimde daha iyi performans sergilediğini göstermektedir. Bu

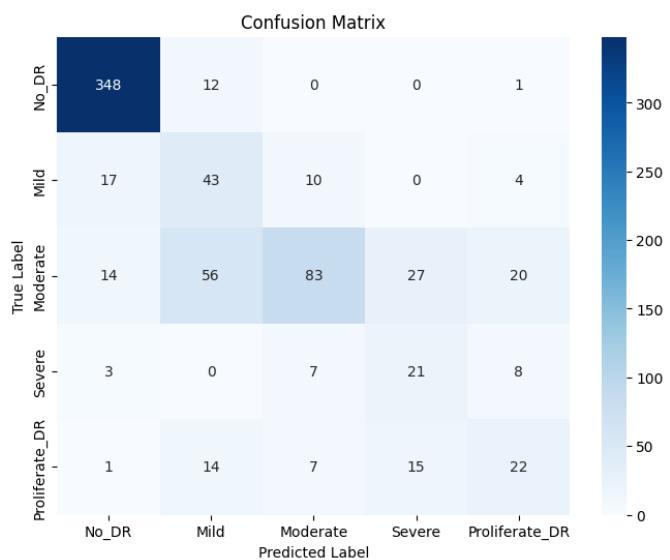


Fig. 3. Confusion Matrix

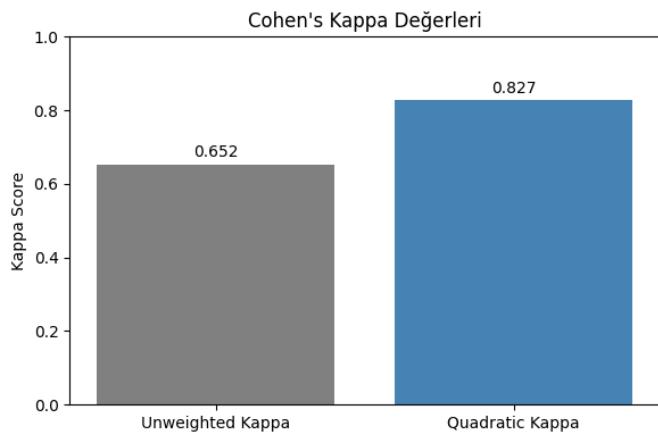


Fig. 4. Cohen's Kappa Tablosu

durum, özellikle az temsil edilen sınıflarda gözlenen performans düşüşüne rağmen modelin genel sınıflandırma tutarlılığının korunduğunu ortaya koymaktadır.

VI. SONUÇ

Bu çalışmada, diyabetik retinopati şiddet seviyelerinin sınıflandırılması problemi, transfer learning tabanlı EfficientNetB0 mimarisini kullanılarak ele alınmıştır. İki aşamalı eğitim stratejisi (warm-up ve fine-tuning) ile modelin ön-eğitimli temsilleri korunmuş, problem alanına özgü özelliklerin kontrollü biçimde öğrenilmesi sağlanmıştır. Sınıf dengesizliği göz önünde bulundurularak kullanılan weighted sparse focal loss ve yumuşatılmış sınıf ağırlıkları, özellikle az temsil edilen sınıflarda modelin tamamen çökmesini engellemiştir.

Elde edilen sonuçlar, doğruluk metriğine ek olarak sınıf bazlı ölçütler ve Cohen's Kappa değeri ile değerlendirilmiştir. Confusion matrix analizi, model hatalarının çoğunlukla komşu hastalık evreleri arasında gerçekleştiğini göstermiştir.

Quadratic weighted kappa metriği, modelin yaptığı hataların şiddetini dikkate alarak, diyabetik retinopati gibi sıralı sınıflandırma problemlerinde daha anlamlı bir performans değerlendirmesi sunmuştur.

Bu çalışmanın temel sınırlılığı, veri setindeki sınıf dengezisizliği ve az temsil edilen ileri evre sınıfların sayıca yetersiz olmasıdır. Ayrıca, kullanılan veri ön işleme ve veri artırma yöntemleri temel düzeyde tutulmuş, ileri seviye medikal görüntü işleme teknikleri bu çalışma kapsamında değerlendirilmemiştir.